연구 브리프: FL→FU 공격 부류의 정의와 학습 중 방어

(발표자)

2026-10-13

1 한 장 요약

- **막으려는 것.** 특정 두 논문(FUBA, BadFU)이 아니라, 연합학습(*FL*) 중에 심고 연합 언러닝(*FU*)의 삭제로 발동시키는 공격 부류 전체. §2에서 이 부류를 정의하고, 조사한 공격 논문 7편이 그 정의에 들어옴을 표로 보인다.
- **왜 범용성이 가능한가.** 이 부류의 공격은 정의상 "삭제 전에는 보이지 않고 삭제 후에 행동이 바뀐다". 그러려면 (i) 학습 중 어떤 클라이언트의 기여가 다른 기여들을 되돌려 총합에서 지워져야 하고(상쇄), (ii) 삭제 요청자의 기여를 걷어내면 모델의 행동이 남들을 걷어낼 때보다 크게 바뀌어야 한다. 두 조건은 공격의 필요조건이므로, 이것을 재는 방어는 부류 전체에 적용된다. 좁히는 것은 공격 종류가 아니라 서버의 능력(라운드별 기여 보관, 라벨 없는 공개 입력)뿐이다.
- **방어는 두 층.** 학습 중 층 CCD(Cancellation Coalition Detection)는 조건 (i)을 라운드마다 순전파로 재어 요청 전에 표적 클래스·억제자·주입자·복원 라운드를 낸다. 요청 시 층은 조건 (ii)를 "요청자 기여의 일부를 빼 본 모델"에서 모집단 상대 기준으로 재어, (i)이 공개 입력에 새지 않는 공격(BadFU 유형)을 받는다. 대응은 둘 다 공모 집합 배제 후 학습(재개 또는 재학습).
- **지금까지의 숫자(FUBA 논문 설정, 6 궤적).** 학습 중 층: $6/6$ 경보(11–16 라운드), 억제자·주입자 4명 정밀도·재현율 1.0, 소유자 오탐 0. 요청 시 층: 억제자 $3/3$, 소유자 z 0.0. 기존 9개 계열 36개 통계량은 소유자를 같이 잡거나(크기 기준) 주입자를 못 본다(방향 기준). 대응: 공모 집합 배제 재학습 ASR 0.5–0.6%, 정확도 99%; 복원 라운드에서 재개 ASR 0.7%.
- **적응형 공격.** 억제를 약하게 해 탐지를 피하려면 학습 중에 백도어가 드러난다(반합성 실험, §5 그림: 억제를 10%만 줄여도 학습 종료 ASR 43%, 탐지 점수는 여전히 $|z| = 14.9$). 주입자를 늘리면 주입자 식별은 약해지나 억제자 탐지는 남는다. 억제자를 나누면 음의 기여 집합 규칙으로 받는다.

2 공격 부류의 정의: FL→FU 공격

설정. K 클라이언트, T 라운드 FedAvg. 서버는 라운드별 가중 업데이트 U_j^t를 보관한다(FU 서버의 전제). 클라이언트 k의 삭제 요청에 서버는 연산자 R로 θ_T에서 k의 기여를 걷어낸 $R(\theta_T, k)$를 낸다. 서버는 라벨 없는 공개 입력 X_p를 가진다.

정의 1 (삭제 활성화 공격). 적대적 집합 M과 요청자 집합 $S \subseteq M$에 대해, 어떤 입력 집합 X^*와 목표 행동 g가 있어

$$\text{(잠복)} \quad \theta_T \text{ 는 } X^* \text{ 에서 정상}, \qquad \text{(활성화)} \quad R(\theta_T, S) \text{ 는 } X^* \text{ 에서 } g \text{ 를 따름}. \tag{1}$$

백도어($g =$ 표적 클래스)는 특수한 경우이며, 삭제로 남의 입력을 틀리게 만드는 공격($g =$ 오분류)도 포함된다.

정의 1이 함의하는 두 필요조건.

(i) **상쇄.** 1차 선형화에서 $R(\theta_T, S) - \theta_T \approx -U_S$이므로, 잠복과 활성화가 함께 성립하려면 X^* 위에서 $J_{X^*} U_S \neq 0$이고 $J_{X^*}(U_S + \sum_{j \in M \setminus S} U_j) \approx 0$. 즉 S의 기여는 다른 적대적 기여들을 되돌리는 것이어야 한다. 정직한 클라이언트의 손실에는 남의 학습을 되돌리는 항이 없다.

(ii) **삭제 민감도.** S를 걷어낸 모델의 행동 변화는 같은 양만큼 다른 클라이언트를 걷어낸 변화보다 커야 한다(그렇지 않으면 활성화가 아니다).

조사한 공격 논문의 위치.

논문	심는 쪽 / 되돌리는 쪽	요청 단위	정의 1에 들어오는가
FUBA (2025)	클라 4명 / 적대적 방어자 1명 (일관성 손실)	클라이언트	들어옴. 상쇄가 공개 입력에 샘 → 학습 중 층
BadFU (2025)	백도어 표본 클라 / 위장 표본 클라	클라이언트	들어옴. 15 라운드 궤적에서 공개 입력에 안 샘 → 요청 시 층
UBA-Inf (2024)	오염 표본 / 영향 함수로 최적화한 위장 표본	표본	들어옴. vanishing/exposure 보고 = 상쇄 크기를 맞춰야 함
Liu et al. (AAAI 2024)	잠복 트리거 / 언러닝으로 증폭	표본	들어옴
Zhang et al. (2023)	오염 표본 / 완화 표본 (같은 트리거, 원 라벨)	표본	들어옴 (중앙집중형)
Clean-unlearning / clean-label (2025)	분산 / 상충 신호	표본	들어옴 (본문 미확인)
FedMUA (삭제 요청 자체가 해로움)	— / 요청 설계	클라이언트	조건 (ii)만: 요청 시 층이 받음
BadUnlearn (언러닝 과정의 업데이트 조작)	—	—	범위 밖 (삭제 전 잠복이 아님)

결론: "두 공격만 막는다"가 아니라, 정의 1을 만족하는 모든 공격은 (i) 또는 (ii)를 피할 수 없고, 두 층이 각각 (i), (ii)를 잰다. 범용성은 공격 목록이 아니라 필요조건에서 온다.

3 방어

3.1 학습 중 층: CCD

1. **측정.** 라운드 t, 참여자 j: $\Phi_j(c)$ += $\mathrm{mean}_{x \in X_p}[f_c(x; \theta_{t-1} + U_j^t) - f_c(x; \theta_{t-1})]$ (클래스별 누적 기여도; 순전파 1회).
2. **통계량.** 클래스마다 상쇄 지수 $H(c) = 1 - |\sum_j \Phi_j(c)| / \sum_j |\Phi_j(c)|$, 최소 기여 클라이언트 $s(c)$와 그 MAD 표준화 점수 z, 유의한 양의 기여 집합 $\mathcal{P}(c) = \{j : z_j > 2\}$, 양의 기여 집중도 $\rho(c)$.
3. **판정.** 공모 $\Leftrightarrow H \geq 0.8 \wedge z_s \leq -3 \wedge |\mathcal{P}| \geq 2 \wedge \rho \leq 0.6$. 양의 기여가 1명에 집중되면 편중(소유자형)으로 보고 개입하지 않는다. 3 라운드 연속이면 경보.
4. **산출.** 표적 클래스, 억제자 $s(c^*)$, 주입자 $\mathcal{P}(c^*)$, 복원 라운드 t_{back}.

3.2 요청 시 층: 상대 기준 부분 제거 심사 (기존 DOSE)

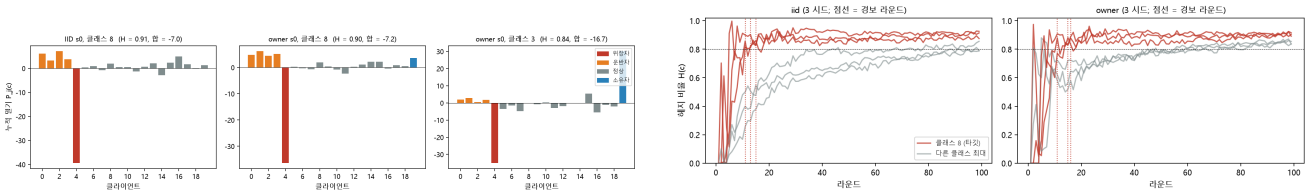
요청자 k의 기여를 비율 ρ(0.1–0.5)만 뺀 모델에서 공개 입력(및 삭제 대상 입력)의 예측 변화를 재고, 다른 모든 클라이언트를 같은 비율로 뺀 변화의 분포(모집단)에 대한 표준화 점수로 판정한다. 절대 변화가 아니라 모집단 상대 기준이므로 데이터가 많은 정상 요청자(소유자)가 오탐되지 않는다(z 0.0). 상쇄가 공개 입력에 새지 않는 공격은 요청 시 삭제 대상 입력 위에서 드러나므로 이 층이 받는다.

3.3 대응 (정화)

공모 집합 $\mathcal{C} = \{s\} \cup \mathcal{P}$. 학습 중이면 $\theta_{t_{\mathrm{back}}}$로 되돌려 $\mathcal{C}$를 배제하고 재개; 학습 후면 $\mathcal{C}$를 배제한 재학습. 요청자의 데이터는 지워진 채이고(재주입 0), 주입자의 기여는 정당성이 없으므로 제거한다. 버린 대안: 요청자 기여 투영 제거(해독제, 논문 설정에서 실패), 재억제 증류(요청자 기여 10% 복원).

4 실험 요약 (FUBA 논문 설정: $K = 20$, 적대적 5, 100 라운드, 참여 0.4, IID·non-IID 각 3 시드)

항목	IID	non-IID(소유자)
공격 재현: 학습 종료 ASR → 억제자 20% 제거 ASR	5.1 → 73.7	5.7 → 71.5
학습 중 층: 경보 라운드/99	13.0±1.6	14.0±2.2
표적·억제자·주입자 4명 정확	3/3	3/3
소유자 오탐 / 비표적 클래스 오경보	—/0	0/0
요청 시 층(flow z): 억제자 검출 / 소유자 z	3/3 / —	3/3 / 0.0
기존 크기 기준(노름·Krum): 소유자 z	—	3.8–6.8 (오탐)
기존 방향 기준(코사인): 억제자 검출	0/3	0/3
대응: 공모 집합 배제 재학습 ASR/ACC	0.5/99.0	0.6/98.9
대응: 복원 라운드 재개 ASR/ACC (1 시드)	0.68/99.08	(예정)
비용	라운드당 9회×500장 순전파	동일

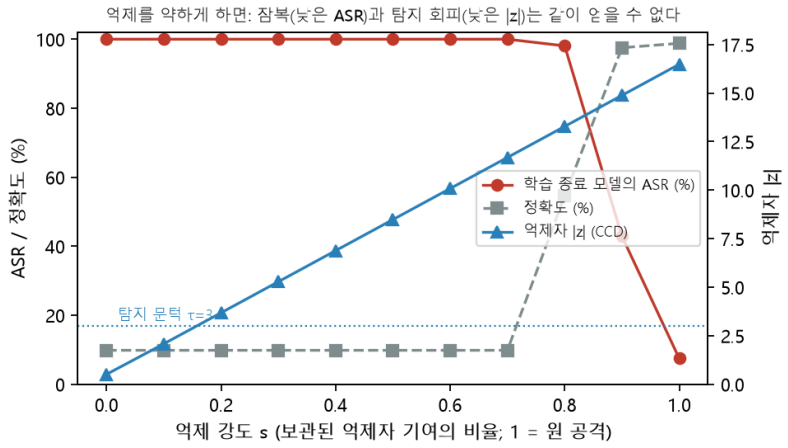


좌: 학습 종료 시 클래스별 누적 기여도(표적 클래스는 주입자 4명이 올리고 억제자 1명이 내림; 소유 클래스는 소유자 1명이 올리고 억제자가 내림). 우: 라운드별 상쇄 지수와 경보 라운드.

5 적응형 공격과 다중 공격자: trade-off

공격자가 움직일 수 있는 것. (A) 억제 강도 s, (B) 주입자 수 $|A|$, (C) 억제자 수 $|S|$, (D) 상쇄의 범위(트리거 영역에만 국한하는가), (E) 공격 강도(트리거 진폭 atk_eps, 주입 기여의 크기).

(A) 억제 강도. 보관된 억제자 기여를 s배로 줄인 반합성 실험(논문 설정 1 시드, 그림). $s = 1$: ASR 7.5, 억제자 $|z|$ 16.5. $s = 0.9$: ASR 42.9 (학습 중 이미 드러남), $|z|$ 14.9. $s \le 0.7$: 모델 붕괴(정확도 9.8). $|z| < 3$이 되는 $s \le 0.2$에서는 모델이 쓸모가 없다. 즉 잠복(낮은 학습 중 ASR)과 탐지 회피(낮은 $|z|$)를 동시에 얻는 s는 없다. 주의: 주입자 학습을 다시 하지 않은 반합성이므로 감도 분석이며, 실제 적응형 공격(억제자 손실 가중치 조정)은 후속 실험이다.



(B) 주입자 수. 저자 코드의 `clients_ratial`로 주입자 8명·억제자 2명($K = 16$) 궤적이 있다. 주입자가 많아져 각자의 기여가 κ 아래로 내려가면 $\mathcal{P}$가 비어 주입자 식별은 못 하지만, 총합은 여전히 억제자를 상쇄해야 하므로 H와 z_s는 남는다(단독 음의 기여로 경보). 즉 공격자는 "주입자 식별 회피"와 "주입자당 기여 축소(= 활성화 후 ASR 감소)" 사이에서 선택한다.

(C) 억제자 수. 억제를 n명에 나누면 각자의 $|z|$가 약 $1/n$로 준다. 음의 기여 집합 규칙 $\mathcal{S}(c) = \{j : z_j \le -\tau\}$로 받으며, n이 커질수록 각자가 문턱 아래로 내려가는 대신 활성화에 n명 전원의 삭제 요청이 필요해진다(요청 시 층이 n번 심사). 억제자 2명 궤적으로 실측 예정.

(D) 상쇄 범위. 공개 입력에 새지 않게 하면 학습 중 층은 못 본다(BadFU 15 라운드: 경보 없음). 그러나 활성화는 정의상 삭제 대상 입력 위에서 일어나므로 요청 시 층이 받는다(BadFU 로컬: 첫 단계 z 8.4). 두 층이 서로의 경계를 덮는다.

(E) 공격 강도 $\leftrightarrow$ ASR $\leftrightarrow$ 탐지 점수. 계획: atk_eps $\in \{0.25, 0.5, 1\}$, 주입자 수 $\in \{4, 8\}$에서 (학습 중 ASR, 삭제 후 ASR, 억제자 $|z|$, 경보 라운드)를 한 표에. 기대: 삭제 후 ASR이 올라갈수록 $|z|$도 단조 증가(둘 다 $|\Phi_S|$에 비례).

6 발전 방안 (순서)

1. **오탐률.** 공격 없는 궤적(MNIST/CIFAR $\times$ IID/non-IID, 생성 중)에서 경보 0회 실측. 명제 2의 근거.
2. **규모.** CIFAR-10/ResNet-18 논문 설정 3 시드(생성 중, 1번 궤적 53/100 라운드). 같은 문턱값으로 동작하는지.
3. **두 번째 공격.** BadFU 40 라운드 3 시드에서 학습 중 층의 경계와 요청 시 층의 보완을 실측.
4. **적응형.** (A) 억제자 손실 가중치 실제 조정, (B)(C) `clients_ratial`=2 궤적, (E) atk_eps 격자 $\rightarrow$ trade-off 표.
5. **강건 집계 위.** Median $\cdot$ Multi-Krum $\cdot$ FLAME $\cdot$ FLDetector 위 12 궤적에서 두 층.
6. **이론.** 명제 $1 \cdot 2$를 가정(전파 비율 η, 정상 기여의 독립$\cdot$산포)과 함께 정리로.

참고. 자세한 초안: `docs/paper/draft_v5.pdf`. 결과 번호: `docs/RESULTS_LOG.md`. 실행: `RUN.md`.